

PROJET 2.3.3: INDEXATION

Table of contents

1	<u>RÉSUMÉ DU PROJET</u>	1
1.1	Contexte métier	1
1.2	Travail demandé	2
2	<u>EXÉCUTION DU PROJET</u>	2
2.1	PARTIE 1	3
2.2	PARTIE 2	3
2.3	PARTIE 3	8
2.4	PARTIE 4	11
2.5	Informations de sessions	12

1 RÉSUMÉ DU PROJET

Dans le cadre de la formation en R, à la fin de chaque nouveau module d'apprentissage, un mini projet doit être produit.

Titre : Audit qualité d'un fichier de notes étudiantes

Objectif : Maîtriser l'indexation et le filtrage logique.

1.1 Contexte métier

Un centre de formation soupçonne plusieurs erreurs dans son fichier de notes. Vous devez identifier et corriger les anomalies.

1.2 Travail demandé

1. Créer :
 - 30 étudiants
 - 30 notes
 2. Introduire volontairement :
 - 3 NA
 - 2 notes aberrantes
 - 2 erreurs de saisie
 3. Utiliser l'indexation pour :
 - localiser les anomalies
 - extraire les étudiants admis
 - extraire les étudiants non admis
 - corriger les erreurs
 4. Produire un mini-rapport expliquant :
 - les erreurs détectées
 - les corrections effectuées
 - les impacts potentiels sur l'analyse
-

2 EXÉCUTION DU PROJET

```
set.seed(2026)
if (requireNamespace("charlatan")) {
  library(charlatan)} else {
  install.packages("charlatan")}
```

Le chargement a nécessité le package : charlatan

2.1 PARTIE 1

Créer :

- 30 étudiants
- 30 notes

```
# Générer 30 noms d'étudiants français à partir de la fonction 'ch_name'
# du package 'charlatan'
noms <- ch_name(n = 30, locale = "fr_FR")
noms
```

```
[1] "William Bourdon"      "Marthe Dubois"
[3] "Julien Vallee"        "Hélène Rousséau"
[5] "Manon-Maryse Duhamel" "Pénélope L'Torres"
[7] "Benjamin Perret"      "Julien Blondel"
[9] "Adrienne Bouchet"     "Antoine Piérre"
[11] "Virginie Leduc"       "Alfred-Roland Rey"
[13] "Robert-François Paul" "René Leroux"
[15] "Paul Rolland"         "Alix d'Jacquét"
[17] "Noël Herve"           "Guillaume-Étienne Blanc"
[19] "Jeanne Carpentier"    "Laetitia Pages"
[21] "Antoine Royér"        "Laetitia Schneidér"
[23] "Aurore-Adélaïde Maury" "Océane Roy d'Munoz"
[25] "Manon Diaz d'Peltier" "Vincent Guyon"
[27] "Eugène Marion"        "Diane-Monique Gomez"
[29] "Luc Blanchet"         "Paulette Besnard d'Blin"
```

```
# Générer 30 notes aléatoires
notes <- round(runif(30, min = 0, max = 20))
notes
```

```
[1] 14 6 10 13 18 1 4 13 13 1 3 1 20 11 15 15 7 14 16 1 2 10 19 2 2
[26] 8 1 9 10 2
```

2.2 PARTIE 2

Introduire volontairement :

- 3 NA
- 2 notes aberrantes
- 2 erreurs de saisie

```
## Introduire 3 NA.
# Décider des nombres de valeurs NA à introduire dans les vecteurs "noms"
# et "notes"
nb_na_noms <- sample(0:3, 1)
nb_na_noms
```

```
[1] 3
```

```
cat("Nombre de valeurs NA à introduire dans le vecteur 'noms':",
    if(length(nb_na_noms) == 0)
      {"Aucune valeur NA à introduire dans le vecteur 'noms'"}
    else {nb_na_noms})
```

Nombre de valeurs NA à introduire dans le vecteur 'noms': 3

```
nb_na_notes <- 3 - nb_na_noms
nb_na_notes
```

```
[1] 0
```

```
cat("Nombre de valeurs NA à introduire dans le vecteur 'notes':",
    if(length(nb_na_notes) == 0)
      {"Aucune valeur NA à introduire dans le vecteur 'notes'"}
    else {nb_na_notes})
```

Nombre de valeurs NA à introduire dans le vecteur 'notes': 0

```
# Déterminer de façon aléatoire les positions des NA dans le vecteur
# "noms" et "notes"
positions_na_noms <- sample(1:length(noms), nb_na_noms)
positions_na_noms
```

```
[1] 14 21 26
```

```
cat("Positions des valeurs NA à introduire dans le vecteur 'noms':",
    if(length(positions_na_noms) == 0)
      {"Aucune position"}
    else {positions_na_noms})
```

Positions des valeurs NA à introduire dans le vecteur 'noms': 14 21 26

```
positions_na_notes <- sample(1:length(notes), nb_na_notes)
positions_na_notes
```

```
integer(0)
```

```
cat("Positions des valeurs NA à introduire dans le vecteur 'notes':",
    if(length(positions_na_notes) == 0)
      {"Aucune position"}
    else {positions_na_notes})
```

Positions des valeurs NA à introduire dans le vecteur 'notes': Aucune position

```
# Introduire les NA
if (length(positions_na_noms) == 0) {
  print("Aucun NA à introduire dans le vecteur 'noms'")
} else {noms[positions_na_noms] <- NA}
noms
```

[1] "William Bourdon"	"Marthe Dubois"
[3] "Julien Vallee"	"Hélène Rousséau"
[5] "Manon-Maryse Duhamel"	"Pénélope L'Torres"
[7] "Benjamin Perret"	"Julien Blondel"
[9] "Adrienne Bouchet"	"Antoine Piérre"
[11] "Virginie Leduc"	"Alfred-Roland Rey"
[13] "Robert-François Paul"	NA
[15] "Paul Rolland"	"Alix d'Jacquét"
[17] "Noël Herve"	"Guillaume-Étienne Blanc"
[19] "Jeanne Carpentier"	"Laetitia Pages"
[21] NA	"Laetitia Schneider"
[23] "Aurore-Adélaïde Maury"	"Océane Roy d'Munoz"
[25] "Manon Diaz d'Peltier"	NA
[27] "Eugène Marion"	"Diane-Monique Gomez"
[29] "Luc Blanchet"	"Paulette Besnard d'Blin"

```
if (length(positions_na_notes) == 0) {
  print("Aucun NA à introduire dans le vecteur 'notes'")
} else {notes[positions_na_notes] <- NA}
```

```
[1] "Aucun NA à introduire dans le vecteur 'notes'"
```

```
notes
```

```
[1] 14  6 10 13 18  1  4 13 13  1  3  1 20 11 15 15  7 14 16  1  2 10 19  2  2  
[26]  8  1  9 10  2
```

```
## Introduire 2 notes aberrantes  
positions_aber_notes <- if(length(positions_na_notes) == 0)  
{sample(1:length(notes), 2)} else {  
  sample((1:length(notes))[-c(positions_na_notes)], 2)}  
  
cat("Positions des valeurs aberrantes dans le vecteur 'notes' :",  
    positions_aber_notes)
```

```
Positions des valeurs aberrantes dans le vecteur 'notes' : 6 19
```

```
notes[positions_aber_notes] <- c(200, 102)
```

```
## Introduire 2 erreurs de saisie  
# Remplacer des noms ou des notes dans les vecteurs 'notes' et 'noms'  
# Choisir de façon aléatoire le nombre et les positions des erreurs  
# de saisie à introduire dans les vecteurs 'noms' et 'notes'  
nb_err_noms <- sample(0:2, 1)  
cat("Nombre des erreurs de saisie à introduire dans le vecteur 'noms': ",  
    nb_err_noms)
```

```
Nombre des erreurs de saisie à introduire dans le vecteur 'noms': 0
```

```
nb_err_notes <- 2 - nb_err_noms  
cat("Nombre des erreurs de saisie à introduire dans le vecteur 'notes': ",  
    nb_err_notes)
```

```
Nombre des erreurs de saisie à introduire dans le vecteur 'notes': 2
```

```
if (length(positions_na_noms) != 0) {  
  positions_err_noms <- sample(1:length(noms)[-c(positions_na_noms)],  
                              nb_err_noms)} else {  
  positions_err_noms <- sample(1:length(noms),  
                              nb_err_noms)}  
  
cat("Positions des erreurs de saisie à introduire dans le vecteur 'noms': ",  
    positions_err_noms)
```

Positions des erreurs de saisie à introduire dans le vecteur 'noms':

```
if (length(positions_na_notes) != 0 & length(positions_aber_notes) != 0)
{positions_err_notes <- sample(1:length(notes)[-c(positions_na_notes,
                                                    positions_aber_notes)],
                              nb_err_notes)} else {
  if (length(positions_na_notes) != 0 &
      length(positions_aber_notes) == 0)
  {positions_err_notes <- sample(
    1:length(notes)[-c(positions_na_notes)],
    nb_err_notes)} else {
    if (length(positions_na_notes) == 0 &
        length(positions_aber_notes) != 0)
    {positions_err_notes <- sample(
      1:length(notes)[-c(positions_aber_notes)
                        ],
      nb_err_notes)} else {
      if (length(positions_na_notes) == 0 &
          length(positions_aber_notes) == 0)
      {positions_err_notes <- sample(
        1:length(notes),
        nb_err_notes)}}}}
cat("Positions des erreurs de saisie à introduire dans le vecteur 'notes': ",
    positions_err_notes)
```

Positions des erreurs de saisie à introduire dans le vecteur 'notes': 2 21

```
# Utiliser des lettres pour simuler des erreurs de saisies
noms[positions_err_noms] <- sample(LETTERS, nb_err_noms)
noms
```

[1] "William Bourdon"	"Marthe Dubois"
[3] "Julien Vallee"	"Hélène Rousséau"
[5] "Manon-Maryse Duhamel"	"Pénélope L'Torres"
[7] "Benjamin Perret"	"Julien Blondel"
[9] "Adrienne Bouchet"	"Antoine Piérre"
[11] "Virginie Leduc"	"Alfred-Roland Rey"
[13] "Robert-François Paul"	NA
[15] "Paul Rolland"	"Alix d'Jacquét"
[17] "Noël Herve"	"Guillaume-Étienne Blanc"
[19] "Jeanne Carpentier"	"Laetitia Pages"
[21] NA	"Laetitia Schneider"
[23] "Aurore-Adélaïde Maury"	"Océane Roy d'Munoz"
[25] "Manon Diaz d'Peltier"	NA

```
[27] "Eugène Marion"      "Diane-Monique Gomez"  
[29] "Luc Blanchet"       "Paulette Besnard d'Blin"
```

```
notes[positions_err_notes] <- sample(LETTERS, nb_err_notes)  
notes
```

```
[1] "14" "D"  "10" "13" "18" "200" "4"  "13" "13" "1"  "3"  "1"  
[13] "20" "11" "15" "15" "7"  "14" "102" "1"  "U"  "10" "19" "2"  
[25] "2"  "8"  "1"  "9"  "10" "2"
```

2.3 PARTIE 3

Utiliser l'indexation pour :

- localiser les anomalies
- extraire les étudiants admis
- extraire les étudiants non admis
- corriger les erreurs

```
## Localiser les anomalies  
str(noms)
```

```
chr [1:30] "William Bourdon" "Marthe Dubois" "Julien Vallee" ...
```

```
any(is.na(noms))
```

```
[1] TRUE
```

```
typeof(noms)
```

```
[1] "character"
```

```
str(notes)
```

```
chr [1:30] "14" "D" "10" "13" "18" "200" "4" "13" "13" "1" "3" "1" "20" ...
```

```
any(is.na(notes))
```

```
[1] FALSE
```

```
typeof(notes)
```

```
[1] "character"
```

```
## Extraire les étudiants admis d'une part et les étudiants non admis  
# d'autres part. Mais avant, nettoyer le vecteur 'notes' qui est  
# actuellement en 'character' alors qu'il est censé être de type 'numeric'  
# Transformer les valeurs textuelles dans le vecteur 'notes' en valeurs NA.  
notes_clean <- notes  
notes_clean <- as.numeric(notes_clean)
```

Warning: NAs introduits lors de la conversion automatique

```
notes_clean
```

```
[1] 14 NA 10 13 18 200 4 13 13 1 3 1 20 11 15 15 7 14 102  
[20] 1 NA 10 19 2 2 8 1 9 10 2
```

```
# Transformer aussi les valeurs aberrantes en NA  
notes_clean[notes_clean > 20] <- NA  
notes_clean
```

```
[1] 14 NA 10 13 18 NA 4 13 13 1 3 1 20 11 15 15 7 14 NA 1 NA 10 19 2 2  
[26] 8 1 9 10 2
```

```
# Les positions des étudiants admis et non admis dans le vecteur  
# 'notes_clean'.  
# Supposer que la note minimale d'admission est égale à 12/20  
admission <- ifelse(notes_clean >= 12, "Admis", "Non admis")  
admission
```

```
[1] "Admis" NA "Non admis" "Admis" "Admis" NA  
[7] "Non admis" "Admis" "Admis" "Non admis" "Non admis" "Non admis"  
[13] "Admis" "Non admis" "Admis" "Admis" "Non admis" "Admis"  
[19] NA "Non admis" NA "Non admis" "Admis" "Non admis"  
[25] "Non admis" "Non admis" "Non admis" "Non admis" "Non admis" "Non admis"
```

```
notes_positions_admis <- which(admission == "Admis")  
notes_positions_admis
```

```
[1] 1 4 5 8 9 13 15 16 18 23
```

```
notes_positions_non_admis <- which(admission == "Non admis")
notes_positions_non_admis
```

```
[1] 3 7 10 11 12 14 17 20 22 24 25 26 27 28 29 30
```

```
# Utiliser les positions pour obtenir les noms des étudiants
# admis et non admis
admis <- c(na.omit(noms[notes_positions_admis]))
cat("Les étudiants admis sont : ", "\n", paste(admis, collapse = "\n "))
```

Les étudiants admis sont :

William Bourdon
Hélène Rousséau
Manon-Maryse Duhamel
Julien Blondel
Adrienne Bouchet
Robert-François Paul
Paul Rolland
Alix d'Jacquét
Guillaume-Étienne Blanc
Aurore-Adélaïde Maury

```
non_admis <- c(na.omit(noms[notes_positions_non_admis]))
cat("Les étudiants non admis sont : ", "\n", paste(non_admis, collapse = "\n "))
```

Les étudiants non admis sont :

Julien Vallee
Benjamin Perret
Antoine Pierre
Virginie Leduc
Alfred-Roland Rey
Noël Herve
Laetitia Pages
Laetitia Schneidér
Océane Roy d'Munoz
Manon Diaz d'Peltier
Eugène Marion
Diane-Monique Gomez
Luc Blanchet
Paulette Besnard d'Blin

```
# Bonus : Les étudiants sans notes ou dont les notes sont mal saisies
notes_positions_manquants <- which(is.na(admission))
notes_positions_manquants
```

```
[1] 2 6 19 21
```

```
noms_notes_manquants <- c(na.omit(noms[notes_positions_manquants]))
cat("Les étudiants dont les notes ne sont pas retrouvées ou ont été mal saisies:",
    "\n", paste(noms_notes_manquants, collapse = "\n "))
```

Les étudiants dont les notes ne sont pas retrouvées ou ont été mal saisies:

Marthe Dubois

Pénélope L'Torres

Jeanne Carpentier

2.4 PARTIE 4

Produire un mini-rapport expliquant :

- les erreurs détectées
- les corrections effectuées
- les impacts potentiels sur l'analyse

Les erreurs détectées

1) Le vecteur "notes" est de type "character", c'est-à-dire que R considère qu'il contient des données textuelles; ce qui n'est pas normalement le cas. Ce problème est arrivé lors de l'insertion des "erreurs de saisies" dans la partie 2 du projet. En insérant des lettres, qui sont des textes, dans le vecteur "notes", R a fait une conversion de tous les éléments du vecteur en valeurs textuelles.

2) De plus, il y avait des valeurs aberrantes ou extrême comme 200 et 102

3) Par ailleurs, les vecteurs "notes" et "noms" contenaient tous les deux des valeurs manquantes (NA)

Les corrections effectuées

1) Premièrement, le vecteur "notes" qui était de type "character" à cause de la conversion automatique de R a été converti en vecteur numérique grâce à la fonction "as.numeric". Pour ce qui est des valeurs textuelles présentes dans le vecteur, la fonction "as.numeric" les convertit immédiatement en valeurs NA car elle ne peut

naturellement pas effectuer de conversion numérique sur des données textuelles.

2) Deuxièmement, en ce qui concerne les valeurs aberrantes identifiées dans le vecteur "notes", elles ont été converties en NA pour ne pas biaiser les résultats des analyses, vu que l'on ne peut pas réellement savoir quelles sont les véritables notes

```
## Les impacts potentiels sur l'analyse
L'utilisation du vecteur "notes" tel quel, aurait entraîner des erreurs car aucune
analyse destinée au traitement de données numériques n'aurait pu être effectuée sur
les valeurs textuelles contenu dans le vecteur "notes". Par exemple un calcul de la
moyenne de toutes les notes auraient résulter sur une erreur, car ces dernières sont
en format textuel dans le vecteur "notes"
```

2.5 Informations de sessions

```
sessionInfo()
```

```
R version 4.6.0 (2026-04-24 ucrt)
Platform: x86_64-w64-mingw32/x64
Running under: Windows 11 x64 (build 26100)
```

```
Matrix products: default
  LAPACK version 3.12.1
```

```
locale:
[1] LC_COLLATE=French_France.utf8  LC_CTYPE=French_France.utf8
[3] LC_MONETARY=French_France.utf8 LC_NUMERIC=C
[5] LC_TIME=French_France.utf8
```

```
time zone: Atlantic/Cape_Verde
tzcode source: internal
```

```
attached base packages:
[1] stats      graphics  grDevices  utils      datasets  methods    base
```

```
other attached packages:
[1] charlatan_0.6.2
```

```
loaded via a namespace (and not attached):
[1] digest_0.6.39      R6_2.6.1            fastmap_1.2.0       xfun_0.60
```

[5]	magrittr_2.0.5	glue_1.8.1	tibble_3.3.1	knitr_1.51
[9]	pkgconfig_2.0.3	htmltools_0.5.9	rmarkdown_2.31	lifecycle_1.0.5
[13]	tinytex_0.60	cli_3.6.6	vctrs_0.7.3	compiler_4.6.0
[17]	rstudioapi_0.19.0	tools_4.6.0	whisker_0.4.1	pillar_1.11.1
[21]	evaluate_1.0.5	yaml_2.3.12	otel_0.2.0	rlang_1.3.0
[25]	jsonlite_2.0.0			